A · Solo color

E1: se entrena solo la cabeza
E1u: también la etapa 4

Imagen RGB

EfficientViT-B1
ADE20K · tallo y etapas 1–3 congeladas

Etapa 4 · 1/32
congelada: E1
ajustada: E1u (lr × 0.1)

$f_2 \cdot 1/8$
$f_3 \cdot 1/16$
$f_4 \cdot 1/32$

Cabeza de EfficientViT-Seg
se entrena · lee 1/8, 1/16 y 1/32

Segmentación · 40 clases

no usa profundidad

B · Fusión en la cabeza

suma: E2, E2h, E2u, E10, E2c, E2cd
MLCA: E4, E5, E3c, E3cd, E4c, E4cd, E4cf, E4cfd

Imagen RGB

EfficientViT-B1
ADE20K · tallo y etapas 1–3 congeladas

Etapa 4 · 1/32
congelada: v3 y familia «c»
ajustada: E2u, E10

Profundidad

DeFM ResNet-18
congelado preentrenado en profundidad

C3 · P4 · C5
E2, E2h, E2u, E4, E5: P3 · P4 · P5

$f_2 \cdot 1/8$
$f_3 \cdot 1/16$
$f_4 \cdot 1/32$
fusión en 1/8, 1/16 y 1/32

suma | MLCA

Cabeza de EfficientViT-Seg
se entrena · lee 1/8, 1/16 y 1/32

Segmentación · 40 clases

C · Fusión también en el codificador

suma: E11, E11d, E11r
MLCA: E3e, E4e, E4ed, E3er, E4er

Imagen RGB

EfficientViT-B1
ADE20K · tallo y etapas 1–3 congeladas

Profundidad

DeFM ResNet-18
congelado preentrenado en profundidad

F' = suma | MLCA
P4 · 1/16

Etapa 4 · 1/32
ajustada · lr × 0.1

C3 · P4 · C5

$f_2 \cdot 1/8$
$f_3 \cdot 1/16$
$f_4 \cdot 1/32$
en la cabeza, siempre sumas

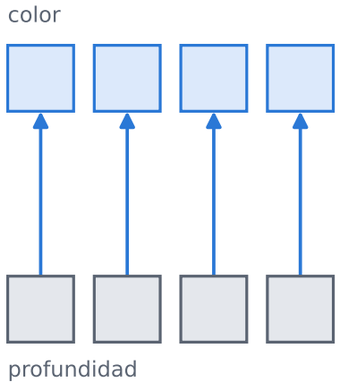
suma

Cabeza de EfficientViT-Seg
se entrena · lee 1/8, 1/16 y 1/32

Segmentación · 40 clases

congelado · se entrena · congelada o ajustada, según el experimento · suma · MLCA

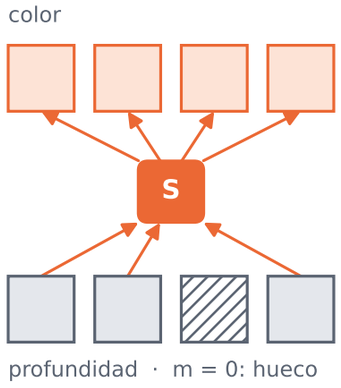
Suma



$$g = f + W\,d$$

W: convolución 1×1 sin sesgo, empieza en 0 (g = f)
cada posición recibe la profundidad de su posición
no usa la máscara: un hueco entra como profundidad 0
el «f +» es la conexión residual: f pasa intacto

MLCA — atención cruzada lineal enmascarada



$$g = f + W_o\,o, \qquad o_i = \varphi(q_i)^\top S \,/\, (\varphi(q_i)^\top z + \varepsilon)$$

$$S = \sum_j m_j\,\varphi(k_j)\,v_j^\top, \quad z = \sum_j m_j\,\varphi(k_j), \quad \varphi = \mathrm{ReLU}$$

q del color; k y v de la profundidad; W_o empieza en 0
todas las posiciones reciben el mismo resumen S
de la imagen entera, sin información de posición
m = validez: binaria (E4) o 1 en todas (E3)
sin profundidad: o = 0 y g = f (queda la residual)